users-research架构-3.17版（简化）

AI用研Agent (v2.0) 技术架构与执行 PRD

一、 产品定义与能力边界

- 产品定位：一个基于AI的轻量用户研究与判断增强系统 。
- 核心价值：通过整合线上数据、历史案例、行业资料、轻量访谈与模拟用户输入，在明确证据等级的前提下，输出判断型或证据型报告 。
- 能力红线：绝对不代替正式的用户研究 。
- 能力红线：绝对不伪造或假设真实的用户态度 。
- 能力红线：不做严格推断和因果证明 。
- 能力红线：对于高度主观或证据缺失的问题，强制触发熔断，提示“需要进一步用研” 。

二、 全局工作流编排 (LangGraph State)

系统基于 LangGraph 进行图结构状态流转，全局状态机需维护以下关键字段以确保信息无损透传 ：

- original_query / uploaded_design：原始文本命题或设计原稿 。
- sub_questions：Node 1 降维拆解后的研究目标集 。
- evidence_pool：包含内部 RAG 数据与外部 Web Search 结果，附带 Tier 等级打标 。
- rq_level：整体证据命中情况（RQ0-RQ3） 。
- synthesis_report：最终输出的结构化卡片或报告 。

三、 核心节点执行规范 (Node Specifications)

1. Node 1: 问题澄清与拆解 (Problem Decomposer)

- 核心任务：拦截模糊命题，执行降维拆解 。
- 拆解规则：强制将问题拆分为 2-4 个子问题 。
- 结构要求：明确每个子问题的目标人群、使用场景、行为路径与决策点 。
- 模型调度：由 GLM-5 或 Doubao-Seed-2.0-pro 负责，依靠其强大的指令遵循和 JSON 结构化输出能力 。

2. Node 2: 双轨证据整合与对齐 (Pattern Analyzer)

- 核心任务：跨来源证据提取、对齐与质量评级 。
- 内部 RAG：调用本地知识库，提取日志指标（Tier 1）与历史报告（Tier 1/2） 。

- 外部 Web Search：调用搜索引擎 API，严格限定在行业白名单站点（如 36Kr、woshipm 等）进行实时知识检索 。
- 清洗与定级：剥离噪音，执行一致性与冲突点交叉校验 。
- 质量评估：判定最终的命中质量等级，划分为 RQ0 至 RQ3 。
- 模型调度：由 Kimi-K2.5 主导，利用超长上下文处理海量 RAG 切片与网页摘要 。

3. Node 3: 判断与报告合成 (Judgment Synthesizer)

- 核心任务：戴着防幻觉镣铐，合成最终商业判断 。
- 防幻觉规则 1：每条输出强制包含判断内容、证据来源、Tier、置信度以及风险 。
- 防幻觉规则 2：明确区分事实与推断，确保推断不等于事实 。
- 输出路由：根据获取的 RQ 等级，自动路由输出“判断信息卡片”、“判断型报告”或“证据型报告”
- 越权熔断：RQ0-1 状态下绝对禁止生成证据型报告 。

4. Node 4A: 视觉预评估中心 (Vision MoE Synthesizer)

- 节点输入：设计原型或页面截图 。
- 并行解析：将设计图同时分发给 GPT-5.2、Gemini 3-Pro-Preview 和 Claude-Sonnet-4.6 进行处理 。
- 底层特征锚定：在进行高层语义推断前，系统会调用图像相似度比对任务（如 CLIP、BLIP 和 ViT 等特征提取模型）。
- 规范对齐：将特征与本地优秀历史规范进行结构对齐，为三大 VLM 提供底层事实约束 。
- 综合共识：提取三大顶尖视觉模型的共识结论 。
- 输出内容：输出结构性推断（非真实眼动）的注意力逻辑、潜在流失点推断与心智风险 。

5. Node 4B: 异构角色模拟沙盒 (Persona Sandbox

- 核心任务：模拟用户注意力分析与假设压力测试 。
- 画像解析：前置处理器读取上传的定性/定量画像文件，提取特征 。
- 模板注入：自动拼装为包含“核心诉求”与“雷区”的严苛 System Prompt 。
- 模型异构分发 (Fan-out)：Kimi-K2.5 生成重度内容消费型等数字用户 A 。
- 模型异构分发 (Fan-out)：MiniMax-M2.5 生成高情绪波动或下沉市场等数字用户 B，利用其优秀的拟人性 。
- 模型异构分发 (Fan-out)：GLM-5 生成严谨比价型等数字用户 C 。
- 模型异构分发 (Fan-out)：Doubao-Seed-2.0-pro 生成效率导向型等数字用户 D 。
- 沙盒对抗与聚类 (Fan-in)：汇总四位“数字用户”对方案的吐槽与反馈，提取高频痛点，暴露分歧点 。
- 强制降级机制：所有沙盒产出的模拟观点强制标注为“Tier 2 模拟生成”。
- 底线原则：沙盒数据严禁跨越 Tier 1 证据线 。

四、 底层技术栈选型规范

- 框架核心：抛弃 Dify 等低代码平台，采用纯代码层面的开源 Agent SDK，以获取对 Prompt、状态流转和 RAG 的绝对控制权 。
- 流程编排引擎：采用 LangGraph 作为主干骨架统领全局，定义整个系统的有向循环工作流 。
- 基座接口标准：月之暗面、MiniMax、智谱 AI 以及火山引擎全部原生支持 OpenAI SDK 的 `/v1/chat/completions` 接口规范 。
- 多模型网关：推荐使用 LiteLLM（通过传参无缝对接切换模型）或部署 One API（统一暴露本地接口，实现模型分流）来管理多模型密钥及并发 。
- 知识库管道：采用 LlamaIndex 纯代码构建本地向量检索 RAG 管道，处理长文本切分与表格解析 。
- 外部检索工具：接入 Google Programmable Search Engine (PSE) 或 Tavily API / Exa AI 建立受控的行业白名单信息流 。

五、 交付物映射标准

交付物类型	触发条件	核心内容要求
判断信息卡片	任意 RQ	5-7条判断，不下最终结论
判断型轻量用研报告	RQ1-RQ2 或指定	明确证据盘点、推断及分歧点
证据型轻量用研报告	仅RQ2-RQ3 且有Tier 1	完整的数据概览、证据交叉与推断限制
设计预评估结果	输入含设计图	注意力逻辑模拟、流失点及验证建议